

DESTEK VEKTÖR MAKİNELERİ

HİLAL SARAÇOĞLU

Öğrenci No: 21360859147

Bölüm: Bilgisayar Mühendisliği

4.Grup

İçindekiler:

Makine Öğrenmesi:	2
Sınıflandırma:	3
Destek Vektör Makineleri:	3
Tarihçe:	3
Destek Vektör Makineleri Nedir?	4
Destek Vektör Makineleri Nasıl Çalışır?	5
Destek Vektör Makineleri Neden Kullanılır?	6
Dvm'in Avantaj ve Dezavantajları	6
Doğrusal ve Doğrusal Olmayan DVM:	7
Hard Margin vs Soft Margin:	8
Destek Vektör Makineleri Kullanım Alanları:	10
KAYNAKÇA:	12

Makine Öğrenmesi:

Makine öğrenmesi (ML), bir bilgisayarın doğrudan yönergeler olmadan öğrenmesine yardımcı olmak için matematiksel modelleri kullanma işlemidir. Bu, yapay zekanın (AI) bir alt kümesi olarak kabul edilir. Makine öğrenmesi, verilerdeki kalıpları belirlemek için algoritmaları kullanır. Tahmin yapabilen bir veri modeli oluşturmak için de bu kalıplar kullanılır. Tıpkı insanların daha fazla alıştırma yaptıkça gelişmesi gibi, veri ve deneyim miktarı arttıkça makine öğrenmesinin sonuçları da daha doğru hale gelir

Makine öğrenmesi algoritmasının öğrenme sistemini üç ana bölüme ayırır.

1. **Bir Karar Süreci:** Genel olarak, makine öğrenmesi algoritmaları bir tahmin ya da sınıflandırma yapmak için kullanılır. Etiketli ya da etiketsiz olabilecek bazı giriş verilerine dayanarak, algoritmanız verilerdeki bir kalıpla ilgili bir tahmin üretecektir.
2. **Bir Hata İşlevi:** Bir hata işlevi, modelin tahminini değerlendirmek için kullanılır. Bilinen örnekler varsa, bir hata işlevi, modelin doğruluğunu değerlendirmek için bir kıyaslama yapabilir.
3. **Bir Model Optimizasyonu Süreci:** Model, eğitim kümesindeki veri noktalarına daha iyi uyuyorsa, bu durumda ağırlıklar bilinen örnek ve model tahmini arasındaki çelişkiyi azaltmak üzere düzenlenir. Algoritma, bu değerlendirmeyi tekrarlayıp süreci eniyileyerek, bir doğruluk eşiğine ulaşılan denge ağırlıkları otonom bir şekilde günceller.

Makine öğrenmesi başlıca Denetimli ve Denetimsiz öğrenme olarak 2'ye ayrılır:

Makine Öğrenmesi		
Denetimli		Denetimsiz
Sınıflandırma	Regresyon	Kümeleme
Destek Vektör Makineleri	Doğrusal Regresyon	K-Ortalamlar
Karar Ağacı	Temel Bileşen Regresyonu	YSA
Naive Bayes	Rastgele Orman	Hiyerarşik Kümeleme
K- En Yakın Komşu	YSA	Temel Bileşenler Analizi
...

Denetimli Makine Öğrenimi

Denetimli makine öğrenimi algoritmaları en yaygın olarak kullanılanlardır. Bu model sayesinde, veri uzmanı bir kılavuz olarak hareket eder ve algoritmaya hangi sonuçlara varması gerektiğini öğretir. Denetimli öğrenim sırasında algoritma tıpkı resimli bir kitaptan ezberleyerek meyveleri öğrenmeye çalışan bir çocuk gibi, daha önceden etiketlenmiş ve önceden tanımlanmış bir çıktısı olan veri kümeleri ile eğitilir.

Denetimli makine öğreniminin örnekleri arasında doğrusal ve lojistik regresyon, çoklu sınıf sınıflandırması ve destek vektör makineleri gibi algoritmalar bulunur.

Sınıflandırma:

Makine öğrenmesi ve istatistikte; sınıflandırma, bilgisayar programının verilen veri girişinden öğrendiği ve sonrasında yeni gözlemleri sınıflandırmak için bu öğrenmeyi kullandığı denetimli öğrenme yaklaşımıdır.

Denetimli öğrenmenin bir başlığı olan Sınıflandırma altındaki algoritmalarından biridir Destek Vektör makineleri.

Destek Vektör Makineleri:

Tarihçe:



(Left to right) J. Rissanen, V. Vapnik, A. Gammerman, A. Chervonenkis, C. Wallace and R. Solomonoff

1963 yılında Vladimir Vapnik ve Alexey Chervonenkis tarafından temelleri atılan “Destek Vektör Makineleri” aslında istatistiksel öğrenme teorisine dayalı bir denetimli öğrenme algoritmasıdır. Her ne kadar temelleri 1963 yılında atılmış olsa da Günümüzdeki standart modeli Corinna Cortes ve Vladimir Vapnik tarafından 1995 yılında geliştirilip sunuldu.


İstatistiksel Öğrenme Teorisi;

- Sistemler matematiksel olarak şu şekilde tanımlanabilir; Verileri (gözlemleri) girdi olarak alır ve gelecekteki verilerin bazı özelliklerini tahmin etmek için kullanılabilecek bir işlev çıkarır. İstatistiksel öğrenme teorisi bunu bir fonksiyon tahmin problemi olarak modeller ve genelleştirme performansı (test verilerinin etiketlenmesinde doğruluk) olarak ölçer.

Destek Vektör Makineleri Nedir?

- Destek Vektör Makineleri temel olarak benzer verileri tanıyıp haritalamak için kullanılan bir sistemdir. Verileri 2 boyutlu veya daha fazla boyutlu düzlemde sınıflandırmak için kullanılır.
- Destek Vektör Makineleri Destek vektör makineleri (DVM), Vapnik-Chervonenkis teorisine dayanan, güçlü temelleri olan denetimli bir makine öğrenme algoritmasıdır.
- N boyutlu bir uzayda optimal bir hiper düzlemi tahmin etmek için eğitim veri setini kullanan ikili bir sınıflandırma tekniğidir.
- Bu hiper düzlem, yeni veri kümelerini sınıflandırmak için kullanılır. İkili bir sınıflandırıcı olan eğitim veri seti, alt düzlemdeki eğitim veri setini iki sınıfa ayırır.
- SVM algoritmaları, verileri 2 boyutlu bir düzlemde olduğu kadar çok boyutlu bir hiper düzlemde sınıflandırmak için kullanılır. Çok boyutlu hiper düzlem, çok boyutlu verileri kategorize etmek için 'Çekirdekleri' kullanır.
- DVM temel olarak 2 sınıfa ait verileri birbirinden en uygun şekilde ayırmak için kullanılır. Bunun için karar sınırları ya da diğer bir ifadeyle hiper düzlemler belirlenir.

Peki bu çizgilerin en optimal doğru olmasını nasıl sağlarız?



Margin Aralığı: Veri kümelerinin tam ortasından bir çizgi çektik ve kırmızı veri kümesinin en yakın verisine ortadan çektığımız mavi çizgiye paralel olacak şekilde kesikli bir çizgi çektik. Mavi veri kümesinin de aynı şekilde en yakın verisine orta çizgiye paralel olacak şekilde kesikli çizgi çektik.

Şekildeki görselde görünen 2 kesikli çizgilerimiz Destek Vektörlerimizdir. Margin aralığımız ise bu 2 kesikli çizginin arasındır.

Kesikli çizgilerin yani destek vektör makinelerinin hesaplanması:

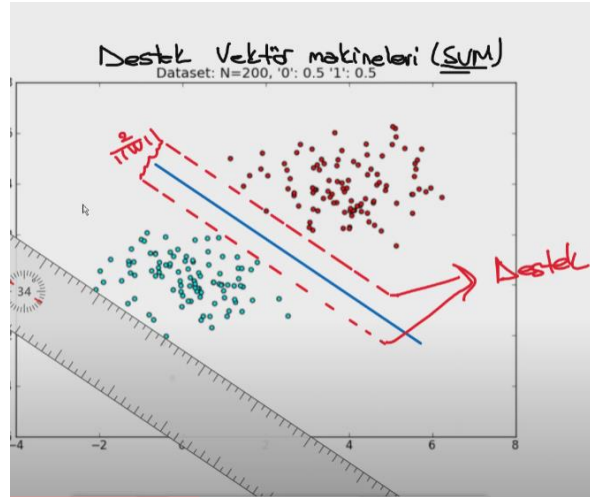
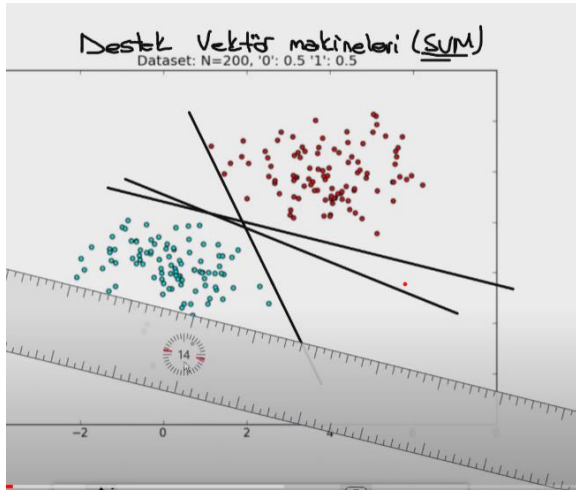
$$\hat{y} = \begin{cases} 0 & \text{if } \mathbf{w}^T \cdot \mathbf{x} + b < 0, \\ 1 & \text{if } \mathbf{w}^T \cdot \mathbf{x} + b \geq 0 \end{cases}$$

W – ağırlık vektörü
X -- girdi vektörü
B – sapma

Margin Aralığı neye göre belirlenir?

Margin ne kadar geniş ise iki veya daha fazla sınıf o kadar iyi ayrıştırılır. Formüle bakacak olursak yeni bir değer için çıkan sonuç 0'a eşit veya büyükse mavi veri kümesinde, değilse kırmızı veri kümesindedir.

2 sınıfı ayırabilecek belki sonsuz sayıda doğru çizilebilir, fakat bizim için önemli olan en optimal yani en uygun karar doğrusunu belirlemektir. Çünkü bu seçim bizim başarımızı etkilemektedir.

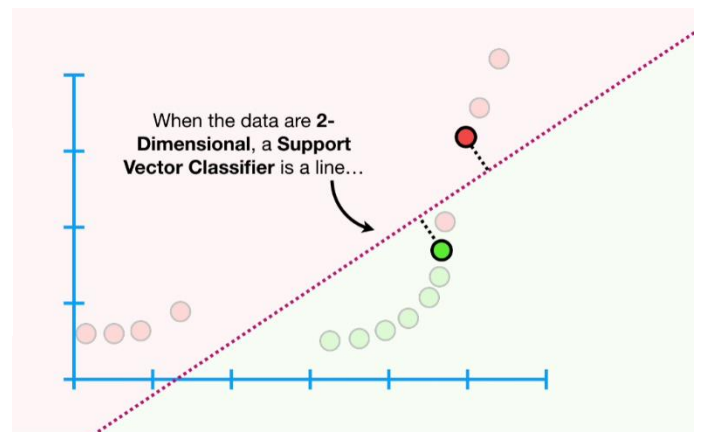



Destek Vektör Makineleri Nasıl Çalışır?

Birçok sınıflandırma çalışmasında karmaşık yapıdaki veri setinden kategoriler ortaya çıkarmaya çalışıyoruz. Yani var olan verilerden bir sınıflandırma yapmaya çalışıyoruz. Sonuçta çıkacak değer ne olduğunu tahmin etmeye çalışıyoruz. Destek vektör makinelerinde de bu amaç için kullanılır ve DVM'in kullandığı metodu böl/parçala/yönet şeklinde özetleyebiliriz.

Böl/parçala/yönet metodu ile biz problemleri burda hep 2'ye ayırıyoruz ve 2'ye ayrılan problemleri tekrar 2'ye ayırabilir miyiz? ayırabilirsek hangi noktasından ayırabiliriz diye çözüm bulmaya çalışıyoruz.

Verileri kümeleyerek daha küçük alt problemlere ayırırız, böylece her bir alt problem bağımsız ve verimli bir şekilde çözülebilir.



Destek Vektör Makineleri Neden Kullanılır?

- Eldeki verilerden yeni kalıpları tanımlamak için büyük miktarda veriyi analiz ederler.
- SVM'ler, özellikle karmaşık küçük veya orta ölçekli veri kümelerinin sınıflandırılması için çok uygundur.
- Yüz tanıma sistemleri, biyoinformatik, çevre bilimleri ve ses analizi gibi birçok konuda kullanılır.
- DVM'ler pazarlama, metin tanıma ve görüntü sınıflandırma gibi birçok gerçek hayat probleminde yaygın olarak kullanılmaktadır. Bu yaygın kullanımın sebebi; diğer yöntemlere göre hesaplama kolaylığı, ölçeklenebilirlik ve aykırı değerlere karşı dayanıklılık konusunda önemli gelişmeler kaydedilmesidir. DVM, az sayıda eğitim verisi ve çok sayıda özellik olduğunda bile sınıflandırma ve regresyon problemlerinde iyi performans gösterir. Ayrıca kullanılan veri sayısının bir üst sınırı yoktur; ultra büyük veri setleri için de uygundur.

Dvm'in Avantaj ve Dezavantajları

DEZAVANTAJ:

- Destek vektörü sınıflandırıcı, veri noktalarını sınıflandırma hiper düzleminin üstüne ve altına koyarak çalıştığından, sınıflandırma için olasılıksal bir açıklama yoktur.
- Destek vektör makinesi algoritması, büyük veri kümeleri için kabul edilemez.
- Hedef sınıflar çakıştığında çok iyi çalışmaz.
- Eğitim süresi çok fazla olabileceğinden büyük veri kümeleri için uygun değildir.



AVANTAJ:

- Doğrusal ve Doğrusal olmayan verilere uygulanabilme
- Yüksek Doğruluk oranı
- Çok sayıda bağımsız değişkenle çalışabilme
- Overfitting sorunun olmaması

Doğrusal ve Doğrusal Olmayan DVM:

Destek Vektör Makineleri 2'ye ayrılır:

- Doğrusal destek vektör makineleri
- Doğrusal olmayan destek vektör makineleri



Doğrusal Destek vektör Makineleri:

- Doğrusal olarak ayrılabilen veriler için kullanılır. Veri kümelerinin tek bir düz çizgi kullanılarak (karar sınırı) iki sınıfa ayrılabilmesidir.

Doğrusal Olmayan Destek vektör Makineleri:


- Veriler doğrusal olarak düzenlenmişse düz bir çizgi kullanarak ayırabiliriz, ancak veri setleri her zaman bir doğru ile ayırabileceğimiz formatta olmayabilir.
- Eğer doğrusal olmayan veri setlerini daha yüksek bir uzayda temsil edebilirsek bir düzlem vasıtasıyla örneklerimizi birbirinden ayırarak sınıflandırma yapabiliriz.

Doğrusal SVM ve Doğrusal Olmayan SVM

Doğrusal SVM	Doğrusal Olmayan SVM
Lineer bir çizgi ile kolayca ayrılabilir.	Doğrusal bir çizgi ile kolayca ayrılamaz.
Veriler hiper düzlem yardımıyla sınıflandırılır.	Ayrılamaz verileri ayrılabilir verilere dönüştürmek için Çekirdekleri kullanırız.
Veriler düz bir çizgi çizilerek kolayca sınıflandırılabilir.	Sınıflandırmak için verileri yüksek boyutlu uzaya eşliyoruz.

Hard Margin vs Soft Margin:

Marginimiz her zaman bu şekilde olmayabilir. Bazen örneklerimiz Margin bölgesine girebilir. Buna Soft Margin denir. Hard Margin, verimiz doğrusal olarak ayrılabilir ve aykırı değerlere karşı çok duyarlıdır. Bu yüzden bazı durumlarda Soft Margin'i tercih etmemiz gerekebilir.



Doğrusal Olmayan DVM:

Kernel Fonksiyonu:


Düşük boyutlar karmaşık veri setlerini açıklamada yeterli olmayabilir. Boyutu arttırsak işlemler artacağı için çok uzun sürer. İşte Kernel Trick burada devreye giriyor. Elimizdeki koordinatları belirli Kernel Fonksiyonları ile çarparak çok daha anlamlı hale getirebiliriz.

Bu yöntemlerden en çok kullanılanlar:

1. *Polynomial Kernel*
2. Gaussian RBF (Radial Basis Function) Kernel

Polynomial Kernel:

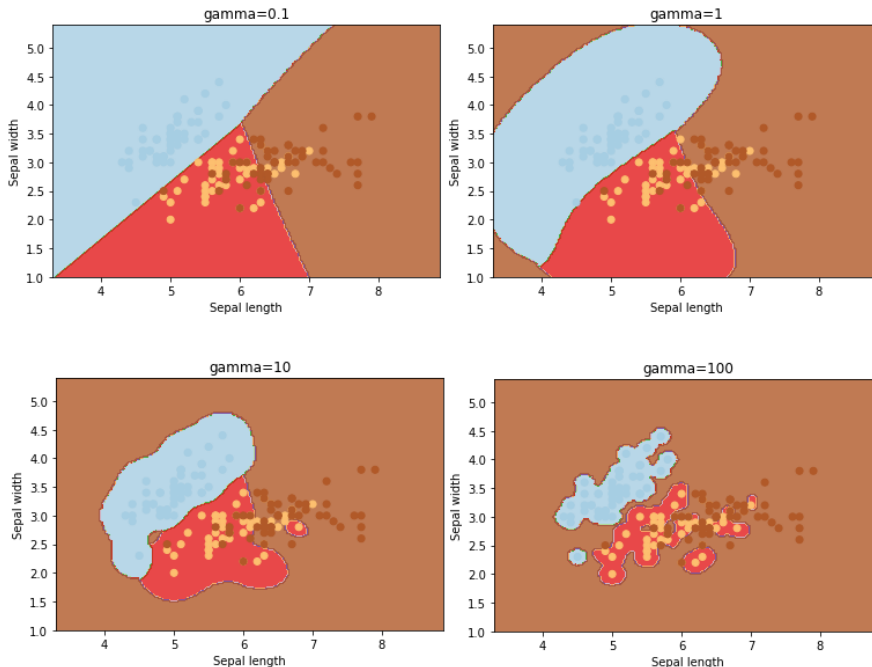
- Bu yöntemde problemimizi çözmek için 2 boyuttan çıkıp 3 veya daha fazlası boyutta işlem yapıyormuş gibi hareket ediyoruz.



- Soldaki (2 boyut) dağılımı bir doğru ile sınıflandıramayız. Bunun için bu gibi problemlerde Polynomial Kernel'i kullanabiliriz. 3. boyutta işlem yaparken sınıflara ayırmak için doğru yerine bir düzlem kullanılırız ve çok daha düzgün bir şekilde sınıflandırabiliriz.
- Modelimiz overfit olmuşsa derecesini düşürmeniz, underfit olmuşsa derecesini yükseltmeniz gerekir.

Gaussian RBF (Radial Basis Function) Kernel

- Sonsuz boyuttaki Destek Vektör Makinelerini bulur ve her bir noktanın belirli bir noktaya ne kadar benzediğini normal dağılım ile hesaplar, ona göre sınıflandırır. Dağılımın genişliğini gamma hiperparametresi ile kontrol ederiz. *Gamma* ne kadar küçükse dağılım o kadar geniş olur. C hiperparametresindeki gibi, model overfit olmuşsa gamma değerini düşürmemiz, model underfit olmuşsa gamma değerini yükseltmemiz gerekir.
- Veri setimiz aşırı büyük değilse genellikle RBF Kernel tercih edilir.



Destek Vektör Makineleri Kullanım Alanları:

- DVM'ler literatürde birçok örüntü uygulamasında kullanılmaktadır. Yüz algılama, metin ve köprü metni sınıflandırma, görüntü sınıflandırma, biyoinformatik, protein çaprazlama, uzaktan homoloji tespiti, el yazısı tanıma, jeoloji ve çevre bilimleri, genelleştirilmiş tahmine dayalı kontrol uygulamaları bunlardan sadece birkaçıdır



Yüz Algılama:

- Görüntünün bölümleri yüz ve yüz olmayan bölümler olarak sınıflandırılır. $N \times N$ boyutundaki görüntüdeki her bir piksel değeri yüz ve yüz olmayan bölümler olarak iki farklı etiketle etiketlenir. Bu veriler eğitim verilerini oluşturur. Sonrasında piksel parlaklığına göre yüzlerin etrafında bir karesel sınır oluşturulur ve her bir görüntü için aynı işlem tekrar edilerek, DVM ile sınıflandırma işlemleri gerçekleştirilir.

Metin Sınıflandırma:

- Metin ve köprü metinlerin sınıflandırılması DVM ile gerçekleştirilebilir. Bu işlem için ilk olarak metinleri; haber makaleleri, e-postalar ve web sayfaları gibi farklı kategorilerde sınıflandırmak için eğitim verileri kullanılır.

Biyoinformatik:

- Hesaplamalı biyoloji alanında, protein homoloji tespiti yaygın bir problemdir. Bu problemi çözmek için kullanılan en etkili yöntemlerden birisi de DVM yöntemidir.

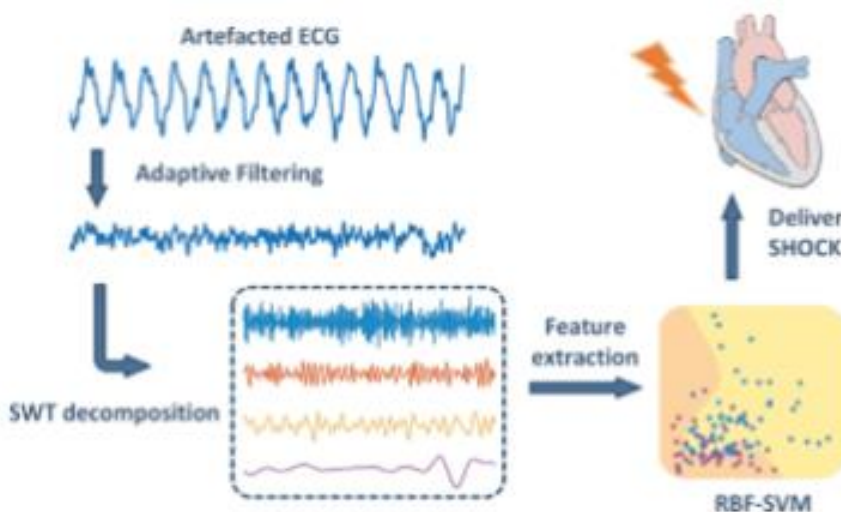
İnternette görmüş olduğum bir IEEE araştırmasına kısaca değinmek istedim.

Pistonla Yönlendirilen Göğüs Kompresyonları Sırasında Kullanıma Yönelik Bir Makine Öğrenen Şok Karar Algoritması:

Kardiyopulmoner resüsitasyon (KPR) sırasında yüksek kaliteli göğüs kompresyonları ve erken defibrilasyon, hastane dışı kardiyak arrestte sonucu iyileştirmenin anahtarıdır. Elektrokardiyogramda (EKG) artefaktlara neden olduklarından, defibrilatörde güvenilir bir şok önerisi kararı için kompresyonlara ara verilmelidir. Bu kesintiler veya uygulama aralıkları, CPR sırasında miyokardiyal ve serebral kan akışını azalttığı ve hastanın hayatta kalma olasılığını önemli ölçüde tehlikeye attığı için hasta için zararlıdır.

Kompresyonlar genellikle kurtarıcılar tarafından manuel olarak verilse de, resüsitasyonda mekanik kompresyon cihazları popüler hale gelmektedir. Mekanik kompresörlerin faydaları, taşıma, invaziv prosedürler veya uzun süreli CPR sırasında bile garantili yüksek kaliteli CPR'yi içerir. Mekanik kompresörler hastane öncesi acil tıpta çok popüler hale geldi, bu nedenle mekanik kompresyonlar sırasında doğru şok karar verme yöntemlerine ihtiyaç duyulmaktadır.

Bu çalışmada, piston tahrikli göğüs kompresyonları sırasında güvenilir bir şok tavsiyesi için yeni bir yöntem sunuyoruz. EKG analiz algoritması, elektrokardiyogramdan kompresyon artefaktlarını çıkarmak için uyarlamalı filtrelemeyi, özellik çıkarımı için çok çözünürlüklü durağan dalgacık dönüşümü (SWT) analizini ve şok/şok yok kararı için bir gaussian destek vektör makinesi (SVM) sınıflandırıcıyı birleştirir. Sonuçlarımız, mekanik kompresyonlar sırasında kalp ritminin doğru bir şekilde teşhis edilebileceğini ve Amerikan Kalp Derneği'nin artefaktsız EKG'de minimum performans gereksinimini karşıladığını göstermektedir. Bu nedenle yöntemimiz, hayati organların perfüzyonunu ve hastanın hayatta kalmasını *tehlikeye atan ritim analizi için uygulamalı aralıklardan kaçınan kesintisiz bir mekanik CPR tedavisine izin verecektir.*



KAYNAKÇA:

1. <https://www.embs.org/tbme/articles/a-machine-learning-shock-decision-algorithm-for-use-during-piston-driven-chest-compressions/>
2. <https://medium.com/deep-learning-turkiye/nedir-bu-destek-vekt%C3%B6r-makineleri-makine-%C3%B6%C4%9Frenmesi-serisi-2-94e576e4223e>
3. <https://yavuz.github.io/destek-vektor-regresyonu-ve-makineleri/>
4. <https://iksadyayinevi.com/wp-content/uploads/2020/12/MAKINE-OGRENMESINDE-TEORIDEN-ORNEK-MATLAB-UYGULAMALARINA-KADAR-DESTEK-VEKTOR-MAKINELERI.pdf>
5. <https://medium.com/@k.ulgen90/makine-%C3%B6%C4%9Frenimi-b%C3%B6l%C3%BCm-4-destek-vekt%C3%B6r-makineleri-2f8010824054>
6. <https://yigitsener.medium.com/destek-vekt%C3%B6r-makineleri-support-vector-machine-svm-%C3%A7a%C4%B1%C5%9Fma-mant%C4%B1%C4%9F%C4%B1-ve-python-uygulamas%C4%B1-992163ff3eec>
7. <https://www.slideshare.net/oguzhantas/destek-vektör-makineleri-support-vector-machine>
8. <https://dergipark.org.tr/tr/download/article-file/1350280>
9. <https://batuhandaz.medium.com/support-vector-machine-destek-vekt%C3%B6r-makinesi-svm-machine-learning-e84378ba2e3c>
10. <https://medium.com/analytics-vidhya/support-vector-machines-math-explained-d48c4edb3d4e>
11. <https://velog.io/@pdestiny2537/Support-Vector-Machine>
12. <https://www.youtube.com/watch?v=ULkhJWsXar8>
13. <https://www.youtube.com/watch?v=nhUq6p1hNrw>
14. <https://www.youtube.com/watch?v=yGQatyHlusA>
15. <https://www.youtube.com/watch?v=yW-lwgpqyIU>
16. <https://www.youtube.com/watch?v=efR1C6CvbmE>
17. <https://towardsdatascience.com/support-vector-machines-illustrated-b48a32c56388>
18. <http://acikerisim.pau.edu.tr/xmlui/bitstream/handle/11499/1501/Osman%20Eray.pdf?sequence=1&isAllowed=y>
19. <https://burakugur.medium.com/destek-vekt%C3%B6r-makinesi-svm-f07f57f0a641>
20. <https://dhirajkumarblog.medium.com/top-4-advantages-and-disadvantages-of-support-vector-machine-or-svm-a3c06a2b107>
21. <https://www.ibm.com/tr-tr/cloud/learn/machine-learning>
22. <https://azure.microsoft.com/tr-tr/resources/cloud-computing-dictionary/what-is-machine-learning-platform>
23. <https://www.oracle.com/tr/artificial-intelligence/machine-learning/what-is-machine-learning/>